

Adaptive Thinking 是否提升 Alaya 认知质量？

诚实的 Null Result 与发布级配对重复实验设计

冻结锚点 c0319d15 / 00a60d75 主指标 ECE (越低越好) 结论 · Null Result

摘要

本报告评估在 Alaya 投研主题智能体中，将 MiniMax-M3 的 MINIMAX_THINKING 从 disabled 切换为 adaptive 是否能提升认知质量。现有真实证据只来自 Phase2 的一次双臂对照：ECE_disabled = 0.2012，ECE_adaptive = 0.2067，观测差 $\Delta = +0.0055$ ，方向上是 disabled 更低、更好。但这是单次观测，没有重复样本、没有方差估计、没有 p 值，不能支持「adaptive 更差」或「disabled 显著更优」的强结论。正确结论是诚实的 null result：当前无证据支持开启 adaptive 来提升认知质量；在缺乏发布级重复证据前，默认 disabled 是更合理、更简单的产品选择。为避免把噪声包装成发现，本报告给出 power analysis，并引用已预注册的 Phase3 配对重复实验设计作为后续可发布结论的路径。

背景

Alaya 的认知质量主指标是 confidence calibration，用 ECE 衡量模型声明置信度与实际正确性的偏差。Phase2 的目标是在 cognition-coverage 场景中验证 calibration 度量能否诚实工作，并据此对 thinking 模式做双臂对照。早期一次结果出现过 bucket-7 注入样本被系统性误判全错的 artifact，使 ECE 虚高到 0.7。这个教训很关键：汇总 ECE 本身不是证据，只有在 correctness truth、bucket 分布和 reliabilityTable 下钻都成立时，ECE 才能进入结论。

度量修复冻结于 commit c0319d15。修复点包括：cognition-coverage-scenario.mjs 为注入样本写入显式 calibrationTruth；health-signal-quality.mjs 改用事件 truth 判定，并且同侧 dedupe/supersede 不计为错。ECE 定义保持为 10 桶 binned 形式： $\sum (n_bucket/N) \cdot |accuracy - confMean|$ 。因此，下文 Phase2 双臂结果可作为可信的单次观测，但不能被升级为发布级因果结论。

观测数据

Phase2 度量修复后的双臂单次结果如下。RUN 目录为 phase2_cog_truth_20260617_134200_base 与 ..._treat；对应预注册为 EXPERIMENT_PREREG_phase2_20260617_125727.md。

arm	ECE	faithfulness	scored/eligible	correctnessMode	providerRatio
disabled	0.2012	0.9388	39/39	all truth	1.0
adaptive	0.2067	0.9410	40/40	all truth	1.0

表 1 · Phase2 双臂单次结果（度量修复后，单次 paired observation，无 p 值）。

主指标观测差为 ECE_adaptive - ECE_disabled = +0.0055，即 disabled 在这一次 run 中更低。faithfulness 方向很小且属于次指标，不能抵消或替代 ECE 主结论。更重要的是，这张表只有一次 paired observation，没有 run 间方差，因此无法给出 p

值、置信区间或等效性结论。它只能支持一句话：在这次可信单次观测中，没有证据显示 adaptive thinking 改善了主指标 ECE。

为何单次 delta 不可信

0.0055 看似有方向，但对 ECE 来说处于噪声量级。cognition-coverage 是高密度人工场景，样本集中在 0.81–0.86 置信区间附近；单桶中 1–2 个样本翻转即可造成 ECE 约 ± 0.02 –0.05 的抖动。因此单次 $\Delta=0.0055$ 不能被当成稳定效应。

预先计算的 power analysis 说明了问题。目标效应 $\delta=0.0055$ ，单侧 $\alpha=0.05$ ，目标功效 0.80，使用配对 t 检验；所需样本量取决于 run 间配对差异标准差 σ_d 。

σ_d	n=8/臂 功效	达 80% 所需 n/臂	n=8 的 MDE
0.004	0.97	5	0.0039
0.006	0.75	9	0.0059
0.008	0.54	15	0.0078
0.010	0.41	22	0.0098
0.015	0.24	48	0.0147

表 2 · Power analysis：所需样本量随 run 间标准差 σ_d 变化。

核心分水岭是：只有当 $\sigma_d \leq \sim 0.005$ 时，n=8/臂 才有 $\geq 80\%$ 功效检出 $\delta=0.0055$ ；当 $\sigma_d \geq 0.010$ 时需 ≥ 22 /臂，优越性检验事实上不可达。Phase2 单次结果没有 σ_d ，因此不能判断当前观测差是否可重复。把 0.0055 写成「发现 adaptive 劣化」或「disabled 显著更优」，都会越过证据边界。

发布级实验设计

发布级实验已在 EXPERIMENT_PREREG_phase3_publication.md 中预注册，冻结点为 commit 00a60d75。设计采用配对重复：同一 pair 内两臂共享 seed 与注入序号，唯一变量是 MINIMAX_THINKING，并定义 $d_i = ECE_{adaptive_i} - ECE_{disabled_i}$ ，正值表示 disabled 更好。

主判据是单侧配对 t 检验，方向为 disabled 在 ECE 上优于 adaptive；只有 $p < 0.05$ 且方向为正才能发布优越性结论。若主判据不显著，才进入 TOST 等效检验，主等效边界 $\Delta=\pm 0.02$ ，敏感性边界 ± 0.01 。重要的是：TOST 只是预注册的回退分析，Phase2 单次结果尚不能证明等效。

每个 run 必须通过 7 道硬门：scored ≥ 30 、coverage ≥ 0.6 、correctnessMode 全 truth、providerRatio=1.0、错误门全 0、bucket-8 accuracy 不得系统性 ≈ 0 、watchdog 绿且 finalDrain complete。Phase3 采用两阶段流程：先跑 pilot 估计 σ_d ，再决定最终 N；只有在 σ_d 足够小时，才有资格追求「disabled 显著优越」的发布结论。

下钻验证纪律

本实验族最大的风险不是统计公式错误，而是把 artifact 当成认知质量差异。Phase2 第一轮已证明，单看汇总 ECE 会误导：bucket-level truth 归因错误会制造虚假的高 ECE。后续任何结论都必须同时检查

reliabilityTable、correctnessMode、providerRatio、错误门和原始事件链。

预注册补充第 4 条尤其重要：如果注入样本所在桶出现系统性 $\text{accuracy} \approx 0$ ，就不能按字面 ECE 下结论，而应判定度量无效并检查 scenario 或 truth 路径。硬门不是形式审查，而是结论合法性的组成部分。

结论

当前结论是诚实 null result：Phase2 单次可信观测没有提供 adaptive thinking 改善认知质量的证据。产品上，默认 MINIMAX_THINKING=disabled 合理，因为它没有在主指标上更差的发布级证据负担，同时避免了 adaptive 带来的 schema 复杂度；历史上 adaptive schema 修复曾将 providerRatio 从 0.58 拉回 1.0，说明它确实增加了工程约束。

但这不等于 adaptive 更差，也不等于已证明两臂等效。若要发布「disabled 显著优越」或「二者等效」，必须按 Phase3 预注册设计跑满配对重复，并让统计结论由真实 σ_d 、有效 run 和预注册判据共同决定。

局限

第一，本报告只覆盖 MiniMax-M3，不外推到其他模型或 provider。第二，cognition-coverage 是人造高密度 scenario（6 个固定 case、confidence 0.81–0.86、集中落在 bucket 8），适合度量校准能力，不代表真实投研全场景。第三， $\text{ECE} \approx 0.20$ 远高于良好校准 < 0.1 ，说明校准绝对水平本身仍是独立产品改进课题，不能通过 thinking 开关讨论替代。第四，Phase2 只有单次观测，没有 run 间方差估计，因此不能直接给出显著性、置信区间或等效结论。

附录 · 可复现性

- Phase2 预注册：EXPERIMENT_PREREG_phase2_20260617_125727.md
- Phase2 RUN：phase2_cog_truth_20260617_134200_base / ..._treat
- 度量修复冻结：commit c0319d15
- Phase3 预注册冻结：commit 00a60d75
- Phase3 预注册：docs/validation/EXPERIMENT_PREREG_phase3_publication.md
- Phase3 执行手册：docs/validation/RUN_PLAYBOOK_phase3.md
- Phase3 分析脚本：analysis/phase3_stats.py, phase3_pilot_decision.py, extract_phase3_metrics.py【均在 analysis/ 下】
- Power analysis 参数： $\delta=0.0055$ ，单侧 $\alpha=0.05$ ，目标功效 0.80，配对 t 检验。